

# ML Algorithms: Methods, Application Scope, and Evidence

This report explains each ML/statistical algorithm used in the project and summarizes its practical application scope.

# ML Algorithms: Methods, Application Scope, and Project Evidence

50 Startups Profit Prediction - 一頁式機器學習演算法技術總覽

## Dataset

### 50 Startups

50 records

## Target

### Profit

Regression

## Best ML model

### Linear Regression

Explainable baseline

## Best features

### R&D + Marketing

Optimized subset

## Performance

### R<sup>2</sup> 0.917

RMSE \$8,206

## 10 algorithm blocks

1

### Pearson Correlation

Filter / 統計關聯

做法: 計算每個數值特徵與 Profit 的線性相關係數, 越接近 +1 表示正向線性關係越強。  
應用: EDA、快速特徵篩選、線性迴歸前置分析、報告中解釋變數與目標的直接關係。  
本案: Top feature: R&D Spend (0.973)

2

### VIF

Filter / 共線性診斷

做法: 以每個特徵被其他特徵解釋的程度計算膨脹因子, 判斷線性迴歸係數是否受共線性影響。  
應用: 線性迴歸、統計建模、風險模型、需要解釋係數的商業報告。  
本案: Highest VIF: R&D Spend (2.47)

3

### SelectKBest F-Regression

Filter / 單變量檢定

做法: 使用 F-test 評估每個特徵與連續目標的統計關聯強度, 依分數排名。  
應用: 快速篩選大量候選特徵、建立模型前的統計排名、資料科學報告。  
本案: Top feature: R&D Spend (F=849.8)

4

### Recursive Feature Elimination

Wrapper / 模型迭代篩選

做法: 用指定模型反覆訓練並移除較弱特徵, 直到保留指定數量的特徵。  
應用: 特徵數中等、需要模型導向選擇、希望比較不同特徵組合的情境。  
本案: Selected: Marketing Spend, R&D Spend

5

### LASSO Regression

Embedded / 正則化選擇

做法: 在迴歸損失中加入 L1 penalty, 使弱特徵係數趨近 0, 達成自動化特徵收縮。  
應用: 高維表格資料、稀疏模型、需要兼顧預測與可解釋性的線性模型。  
本案: CV alpha: 337.63

6

### Random Forest Importance

Embedded / 樹模型重要度

做法: 建立多棵決策樹, 根據特徵降低誤差或分裂貢獻估計重要度。  
應用: 非線性資料、特徵互動、表格資料基準模型、特徵重要度交叉驗證。  
本案: Top feature: R&D Spend (92.33%)

7

### Multiple Linear Regression

Supervised / Regression

做法: 以特徵的線性組合預測連續目標, 透過最小化誤差學習係數。  
應用: 房價、銷售額、成本、利潤、能耗等可解釋性需求高的連續數值預測。  
本案: Optimized R<sup>2</sup>=0.9168, RMSE=\$8,206

8

### Random Forest Regressor

Supervised / Ensemble Regression

做法: 透過多棵決策樹平均預測, 降低單棵樹不穩定性並捕捉非線性。  
應用: 表格資料、非線性預測、特徵重要度、基準模型比較。  
本案: Benchmark R<sup>2</sup>=0.9066, RMSE=\$8,699

9

### K-Fold Cross Validation

Evaluation / 泛化驗證

做法: 將資料切成 K 份輪流訓練與驗證, 降低單次 train/test split 的偶然性。  
應用: 小資料集、模型選擇、調參、作業報告可信度提升。  
本案: 5-fold CV mean R<sup>2</sup>=0.9389

10

### Residual Analysis

Diagnostic / 模型診斷

做法: 分析 Actual - Predicted 的殘差分布, 檢查線性模型是否有系統性偏誤。  
應用: 迴歸模型驗證、錯誤分析、商業風險說明、模型改善方向。  
本案: Residuals mostly centered around zero; low-profit

## Project evidence from the dataset

| Feature         | Correlation | VIF  | RF Importance | Decision        |
|-----------------|-------------|------|---------------|-----------------|
| R&D Spend       | 0.973       | 2.47 | 92.33%        | Keep            |
| Marketing Spend | 0.748       | 2.33 | 6.64%         | Keep            |
| Administration  | 0.201       | 1.18 | 0.72%         | Drop / optional |
| State_Florida   | Categorical | N/A  | 0.15%         | Optional        |
| State_New York  | Categorical | N/A  | 0.16%         | Optional        |

## Recommended optimized ML pipeline



## Final conclusion

R&D Spend is the dominant profit driver. Marketing Spend is the second useful predictor. Administration and State can be kept for baseline comparison, but the optimized model is simpler and more explainable.

# Algorithm Detail Table

| name                          | category                         | method                                       | scope                                | limit                                       | project                                                                 |
|-------------------------------|----------------------------------|----------------------------------------------|--------------------------------------|---------------------------------------------|-------------------------------------------------------------------------|
| Pearson Correlation           | Filter / 統計關聯                    | 計算每個數值特徵與 Profit 的線性相關係數，越接近 +1 表示正向線性關係越強。  | EDA、快速特徵篩選、線性迴歸前置分析、報告中解釋變數與目標的直接關係。 | 只能看線性關係，無法判斷非線性、交互作用，也不等於因果關係。              | Top feature: R&D Spend (0.973)                                          |
| VIF                           | Filter / 共線性診斷                   | 以每個特徵被其他特徵解釋的程度計算膨脹因子，判斷線性迴歸係數是否受共線性影響。      | 線性迴歸、統計建模、風險模型、需要解釋係數的商業報告。          | 主要用於數值特徵與線性模型，不直接衡量預測力。                     | Highest VIF: R&D Spend (2.47)                                           |
| SelectKBest F-Regression      | Filter / 單變量檢定                   | 使用 F-test 評估每個特徵與連續目標的統計關聯強度，依分數排名。          | 快速篩選大量候選特徵、建立模型前的統計排名、資料科學報告。        | 逐一檢查特徵，無法直接考慮特徵之間的組合效果。                     | Top feature: R&D Spend (F=849.8)                                        |
| Recursive Feature Elimination | Wrapper / 模型迭代篩選                 | 用指定模型反覆訓練並移除較弱特徵，直到保留指定數量的特徵。                | 特徵數中等、需要模型導向選擇、希望比較不同特徵組合的情境。        | 計算成本較高，結果會受 estimator 與資料切分影響。              | Selected: Marketing Spend, R&D Spend                                    |
| LASSO Regression              | Embedded / 正則化選擇                 | 在迴歸損失中加入 L1 penalty，使弱特徵係數趨近 0，達成自動化特徵收縮。    | 高維表格資料、稀疏模型、需要兼顧預測與可解釋性的線性模型。        | 特徵高度相關時可能任意選其中一個；alpha 設定需交叉驗證。             | CV alpha: 337.63                                                        |
| Random Forest Importance      | Embedded / 樹模型重要度                | 建立多棵決策樹，根據特徵降低誤差或分裂貢獻估計重要度。                  | 非線性資料、特徵互動、表格資料基準模型、特徵重要度交叉驗證。       | 重要度可能偏好高基數或連續特徵；需搭配 permutation 或 SHAP 更穩健。 | Top feature: R&D Spend (92.33%)                                         |
| Multiple Linear Regression    | Supervised / Regression          | 以特徵的線性組合預測連續目標，透過最小化誤差學習係數。                  | 房價、銷售額、成本、利潤、能耗等可解釋性需求高的連續數值預測。      | 假設關係近似線性，對離群值與遺漏變數敏感。                       | Optimized R2=0.9168, RMSE=\$8,206                                       |
| Random Forest Regressor       | Supervised / Ensemble Regression | 透過多棵決策樹平均預測，降低單棵樹不穩定性並捕捉非線性。                 | 表格資料、非線性預測、特徵重要度、基準模型比較。             | 可解釋性低於線性迴歸，模型較大，外插能力有限。                     | Benchmark R2=0.9066, RMSE=\$8,699                                       |
| K-Fold Cross Validation       | Evaluation / 泛化驗證                | 將資料切成 K 份輪流訓練與驗證，降低單次 train/test split 的偶然性。 | 小資料集、模型選擇、調參、作業報告可信度提升。              | 資料有時間序時不可隨機切分；計算成本高於單次切分。                   | 5-fold CV mean R2=0.9389                                                |
| Residual Analysis             | Diagnostic / 模型診斷                | 分析 Actual - Predicted 的殘差分布，檢查線性模型是否有系統性偏誤。  | 迴歸模型驗證、錯誤分析、商業風險說明、模型改善方向。           | 不是特徵選擇方法，但能指出模型假設或遺漏變數問題。                   | Residuals mostly centered around zero; low-profit cases need attention. |


# Feature Evidence Table

| Feature         | Correlation | VIF      | RFE_Rank | LASSO_Coefficient | RF_Importance |
|-----------------|-------------|----------|----------|-------------------|---------------|
| R&D Spend       | 0.9729      | 2.468903 | 1        | 36173.316844      | 0.923340      |
| Administration  | 0.200717    | 1.175091 | 2        | -300.143181       | 0.007192      |
| Marketing Spend | 0.747766    | 2.326773 | 1        | 3290.919366       | 0.066369      |


| Feature        | Correlation | VIF | RFE_Rank | LASSO_Coefficient | RF_Importance |
|----------------|-------------|-----|----------|-------------------|---------------|
| State_Florida  | N/A         | N/A | 3        | 0.000000          | 0.001500      |
| State_New York | N/A         | N/A | 4        | -0.000000         | 0.001600      |

# Technical Charts


## 01\_pearson\_correlation




## 02\_vif\_multicollinearity




## 03\_selectkbest




## 04\_rfe




## 05\_lasso\_path




06\_random\_forest\_importance



07\_linear\_regression\_actual\_predicted



## 08\_residual\_analysis



## Markdown Report

```
# ML Algorithms - Methods, Application Scope, and One-Page Technical Summary

## Project Context

- Dataset: 50 Startups
- Records: 50
- Target: Profit
- Missing values: 0
- Duplicates: 0
- Optimized model: Linear Regression with R&D Spend + Marketing Spend
- Test R2: 0.9168
- Test RMSE: $8,206.33
- 5-fold CV mean R2: 0.9389

## Algorithm Details

### 1. Pearson Correlation

**Category:** Filter / 統計關聯

**How it works:** 計算每個數值特徵與 Profit 的線性相關係數，越接近 +1 表示正向線性關係越強。

**Practical application scope:** EDA、快速特徵篩選、線性迴歸前置分析、報告中解釋變數與目標的直接關係。

**Limitations:** 只能看線性關係，無法判斷非線性、交互作用，也不等於因果關係。

**Project result:** Top feature: R&D Spend (0.973)

### 2. VIF

**Category:** Filter / 共線性診斷

**How it works:** 以每個特徵被其他特徵解釋的程度計算膨脹因子，判斷線性迴歸係數是否受共線性影響。

**Practical application scope:** 線性迴歸、統計建模、風險模型、需要解釋係數的商業報告。
```



**\*\*Limitations:\*\*** 主要用於數值特徵與線性模型，不直接衡量預測力。

**\*\*Project result:\*\*** Highest VIF: R&D Spend (2.47)

### ### 3. SelectKBest F-Regression

**\*\*Category:\*\*** Filter / 單變量檢定

**\*\*How it works:\*\*** 使用 F-test 評估每個特徵與連續目標的統計關聯強度，依分數排名。

**\*\*Practical application scope:\*\*** 快速篩選大量候選特徵、建立模型前的統計排名、資料科學報告。

**\*\*Limitations:\*\*** 逐一檢查特徵，無法直接考慮特徵之間的組合效果。

**\*\*Project result:\*\*** Top feature: R&D Spend (F=849.8)

### ### 4. Recursive Feature Elimination

**\*\*Category:\*\*** Wrapper / 模型迭代篩選

**\*\*How it works:\*\*** 用指定模型反覆訓練並移除較弱特徵，直到保留指定數量的特徵。

**\*\*Practical application scope:\*\*** 特徵數中等、需要模型導向選擇、希望比較不同特徵組合的情境。

**\*\*Limitations:\*\*** 計算成本較高，結果會受 estimator 與資料切分影響。

**\*\*Project result:\*\*** Selected: Marketing Spend, R&D Spend

### ### 5. LASSO Regression

**\*\*Category:\*\*** Embedded / 正則化選擇

**\*\*How it works:\*\*** 在迴歸損失中加入 L1 penalty，使弱特徵係數趨近 0，達成自動化特徵收縮。

**\*\*Practical application scope:\*\*** 高維表格資料、稀疏模型、需要兼顧預測與可解釋性的線性模型。

**\*\*Limitations:\*\*** 特徵高度相關時可能任意選其中一個；alpha 設定需交叉驗證。

**\*\*Project result:\*\*** CV alpha: 337.63

### ### 6. Random Forest Importance

**\*\*Category:\*\*** Embedded / 樹模型重要度

**\*\*How it works:\*\*** 建立多棵決策樹，根據特徵降低誤差或分裂貢獻估計重要度。

**\*\*Practical application scope:\*\*** 非線性資料、特徵互動、表格資料基準模型、特徵重要度交叉驗證。

**\*\*Limitations:\*\*** 重要度可能偏好高基數或連續特徵；需搭配 permutation 或 SHAP 更穩健。

**\*\*Project result:\*\*** Top feature: R&D Spend (92.33%)

### ### 7. Multiple Linear Regression

**\*\*Category:\*\*** Supervised / Regression

**\*\*How it works:\*\*** 以特徵的線性組合預測連續目標，透過最小化誤差學習係數。

**\*\*Practical application scope:\*\*** 房價、銷售額、成本、利潤、能耗等可解釋性需求高的連續數值預測。

**\*\*Limitations:\*\*** 假設關係近似線性，對離群值與遺漏變數敏感。

**\*\*Project result:\*\*** Optimized R2=0.9168, RMSE=\$8,206

### ### 8. Random Forest Regressor

**\*\*Category:\*\*** Supervised / Ensemble Regression

**\*\*How it works:\*\*** 透過多棵決策樹平均預測，降低單棵樹不穩定性並捕捉非線性。

**\*\*Practical application scope:\*\*** 表格資料、非線性預測、特徵重要度、基準模型比較。

**\*\*Limitations:\*\*** 可解釋性低於線性迴歸，模型較大，外插能力有限。

**\*\*Project result:\*\*** Benchmark R2=0.9066, RMSE=\$8,699

### ### 9. K-Fold Cross Validation

**\*\*Category:\*\*** Evaluation / 泛化驗證

**\*\*How it works:\*\*** 將資料切成 K 份輪流訓練與驗證，降低單次 train/test split 的偶然性。

**\*\*Practical application scope:\*\*** 小資料集、模型選擇、調參、作業報告可信度提升。

**\*\*Limitations:\*\*** 資料有時間序時不可隨機切分；計算成本高於單次切分。

**\*\*Project result:\*\*** 5-fold CV mean R2=0.9389

### 10. Residual Analysis

**\*\*Category:\*\*** Diagnostic / 模型診斷

**\*\*How it works:\*\*** 分析 Actual - Predicted 的殘差分布，檢查線性模型是否有系統性偏誤。

**\*\*Practical application scope:\*\*** 迴歸模型驗證、錯誤分析、商業風險說明、模型改善方向。

**\*\*Limitations:\*\*** 不是特徵選擇方法，但能指出模型假設或遺漏變數問題。

**\*\*Project result:\*\*** Residuals mostly centered around zero; low-profit cases need attention.

## Feature Evidence Table

| Feature         | Correlation         | VIF                | RFE_Rank | LASSO_Coefficient | RF_Importance |  |
|-----------------|---------------------|--------------------|----------|-------------------|---------------|--|
| :-----          | :-----              | :-----             | -----    | -----             | -----         |  |
| R&D Spend       | 0.9729004656594828  | 2.4689030699947017 | 1        | 36173.3           | 0.92334       |  |
| Administration  | 0.20071656826872147 | 1.1750910070550453 | 2        | -300.143          | 0.0071917     |  |
| Marketing Spend | 0.7477657217414767  | 2.326773290530878  | 1        | 3290.92           | 0.0663687     |  |
| State_Florida   | N/A                 | N/A                | 3        | 0                 | 0.00149974    |  |
| State_New York  | N/A                 | N/A                | 4        | -0                | 0.0016        |  |

## Recommended Conclusion

The strongest ML recommendation is to use a compact, explainable Linear Regression pipeline with `R&D Spend` and `Marketing Spend`. The feature-selection evidence consistently shows that R&D is the strongest profit driver, while Marketing is the secondary useful predictor. Administration and State can remain in a baseline comparison model, but they are not essential for the optimized pipeline.